고객을 세그먼테이션하자 [프로젝트]

11-2. 데이터 불러오기

데이터 살펴보기

- **테이블에 있는 10개의 행만 출력하기**

```
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

- **전체 데이터는 몇 행으로 구성되어 있는지 확인하기**

```
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

데이터 수 세기

- **COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기**

```
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

11-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- **각 컬럼 별 누락된 값의 비율을 계산**
  - **각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기**

```
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

결측치 처리 전략

- `StockCode = '85123A'`**의** `Description`**을 추출하는 쿼리문을 작성하기**

```
SELECT # [YOUR QUERY]
FROM project_name.modulabs_project.data
# [YOUR QUERY];
```

[결과 이미지를 넣어주세요]

결측치 처리

- **DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시**

```
DELETE FROM project_name.modulabs_project.data
```

```
WHERE # [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

11-5. 데이터 전처리(2): 중복값 처리

중복값 확인

- **중복된 행의 수를 세어보기**
  - **8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기**

```
SELECT *
FROM project_name.modulabs_project.data
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

중복값 처리

- **중복값을 제거하는 쿼리문 작성하기**
  - **CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트**

```
# [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

11-6. 데이터 전처리(3): 오류값 처리

`InvoiceNo` 살펴보기

- **고유(unique)한 `InvoiceNo`의 개수를 출력하기**

```
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

- **고유한 `InvoiceNo`를 앞에서부터 100개를 출력하기**

```
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

- **`InvoiceNo`가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)**

```
SELECT *
FROM project_name.modulabs_project.data
WHERE # [[YOUR QUERY]]
LIMIT 100;
```

[결과 이미지를 넣어주세요]

- **구매 건 상태가 `Canceled` 인 데이터의 비율(%) - 소수점 첫번째 자리까지**

```
SELECT ROUND(SUM(CASE WHEN # [[YOUR QUERY]] THEN 1 ELSE 0 END)/ # [[YOUR QUERY]], 1)
FROM project_name.modulabs_project.data;
```

[결과 이미지를 넣어주세요]

`StockCode` 살펴보기

- **고유한 `StockCode`의 개수를 출력하기**

```
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

- **어떤 제품이 가장 많이 판매되었는지 보기 위하여 `StockCode` 별 등장 빈도를 출력하기**
  - 상위 10개의 제품들을 출력하기

```
SELECT StockCode, COUNT(*) AS sell_cnt
FROM project_name.modulabs_project.data
# [[YOUR QUERY]]
ORDER BY sell_cnt DESC
# [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

- **`StockCode`의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT DISTINCT StockCode, number_count
FROM (
  SELECT StockCode,
    LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
  FROM project_name.modulabs_project.data
)
WHERE # [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

- **`StockCode`의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

```
SELECT DISTINCT StockCode, number_count
FROM (
  SELECT StockCode,
    LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
  FROM project_name.modulabs_project.data
)
WHERE # [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

- **제품과 관련되지 않은 거래 기록을 제거하기**

```
DELETE FROM project_name.modulabs_project.data
WHERE StockCode IN (
  SELECT DISTINCT StockCode
  FROM (
    # [[YOUR QUERY]]
);
```

[결과 이미지를 넣어주세요]

`Description` 살펴보기

- **고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기**

```
SELECT Description, COUNT(*) AS description_cnt
FROM project_name.modulabs_project.data
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

- **서비스 관련 정보를 포함하는 행들을 제거하기**

```
DELETE
FROM project_name.modulabs_project.data
WHERE
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

- **대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.data AS
SELECT
  * EXCEPT (Description),
  # [[YOUR QUERY]] AS Description
FROM project_name.modulabs_project.data;
```

[결과 이미지를 넣어주세요]

`UnitPrice` 살펴보기

- `UnitPrice`**의 최솟값, 최댓값, 평균을 구하기**

```
SELECT # [[YOUR QUERY]] AS min_price, # [[YOUR QUERY]] AS max_price, # [[YOUR QUERY]] AS avg_price
FROM project_name.modulabs_project.data;
```

[결과 이미지를 넣어주세요]

- **단가가 0원인 거래의 개수, 구매 수량(`Quantity`)의 최솟값, 최댓값, 평균 구하기**

```
SELECT # [[YOUR QUERY]] AS cnt_quantity, # [[YOUR QUERY]] AS min_quantity, # [[YOUR QUERY]] AS max_q
FROM project_name.modulabs_project.data
```

```
WHERE # [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

- `UnitPrice = 0`**를 제거하고 일관된 데이터셋을 유지하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.data AS
SELECT *
FROM project_name.modulabs_project.data
WHERE # [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

11-7. RFM 스코어

Recency

- `InvoiceDate` **컬럼을 연월일 자료형으로 변경하기**

```
select date(invoicedate) as invoiceday, *
from modulabs_project.data;
```

[결과 이미지를 넣어주세요]

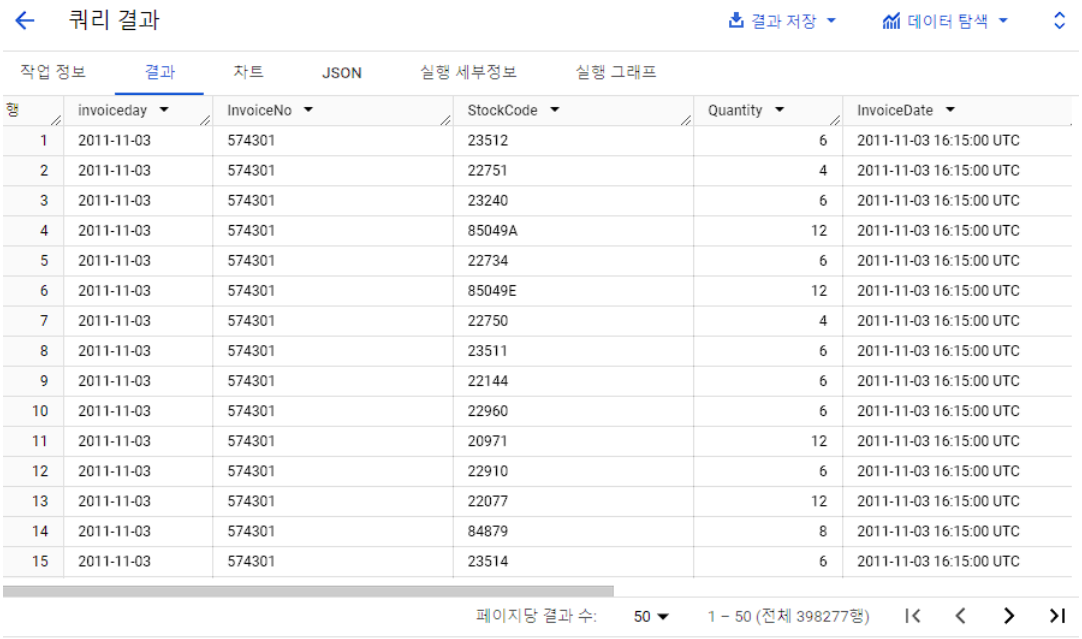

행	invoiceday	InvoiceNo	StockCode	Quantity	InvoiceDate
1	2011-11-03	574301	23512	6	2011-11-03 16:15:00 UTC
2	2011-11-03	574301	22751	4	2011-11-03 16:15:00 UTC
3	2011-11-03	574301	23240	6	2011-11-03 16:15:00 UTC
4	2011-11-03	574301	85049A	12	2011-11-03 16:15:00 UTC
5	2011-11-03	574301	22734	6	2011-11-03 16:15:00 UTC
6	2011-11-03	574301	85049E	12	2011-11-03 16:15:00 UTC
7	2011-11-03	574301	22750	4	2011-11-03 16:15:00 UTC
8	2011-11-03	574301	23511	6	2011-11-03 16:15:00 UTC
9	2011-11-03	574301	22144	6	2011-11-03 16:15:00 UTC
10	2011-11-03	574301	22960	6	2011-11-03 16:15:00 UTC
11	2011-11-03	574301	20971	12	2011-11-03 16:15:00 UTC
12	2011-11-03	574301	22910	6	2011-11-03 16:15:00 UTC
13	2011-11-03	574301	22077	12	2011-11-03 16:15:00 UTC
14	2011-11-03	574301	84879	8	2011-11-03 16:15:00 UTC
15	2011-11-03	574301	23514	6	2011-11-03 16:15:00 UTC

- **가장 최근 구매 일자를 MAX() 함수로 찾아보기**

```
SELECT
   MAX(InvoiceDate) OVER () AS most_recent_date,
   date(InvoiceDate) AS InvoiceDay,
   *
FROM modulabs_project.data;
```

[결과 이미지를 넣어주세요]

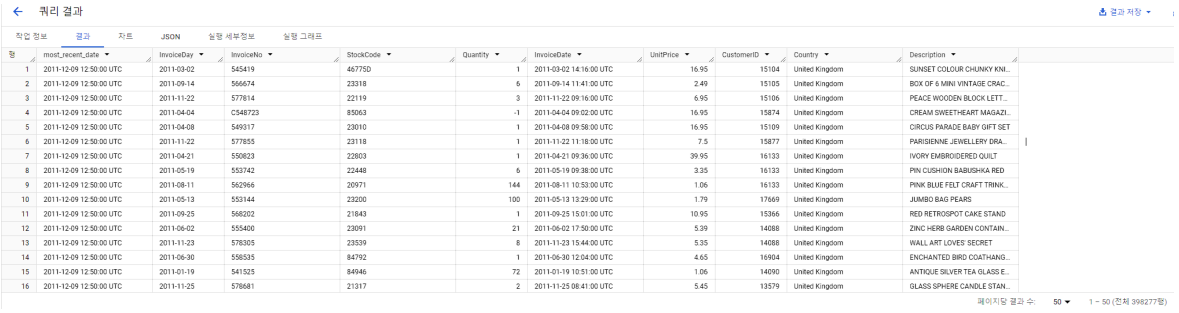

행	most_recent_date	InvoiceDay	InvoiceNo	StockCode	Quantity	InvoiceDate	UnitPrice	CustomerID	Country	Description
1	2011-12-09 12:50:00 UTC	2011-03-02	545419	46775D	1	2011-03-02 14:16:00 UTC	16.95	15104	United Kingdom	SUNSET COLOUR CHUNKY KN...
2	2011-12-09 12:50:00 UTC	2011-09-14	566674	23318	6	2011-09-14 11:41:00 UTC	2.49	15105	United Kingdom	BOX OF 6 MINI VINTAGE CRAC...
3	2011-12-09 12:50:00 UTC	2011-11-22	577814	22119	3	2011-11-22 09:16:00 UTC	6.95	15106	United Kingdom	PEACE WOODEN BLOCK LETT...
4	2011-12-09 12:50:00 UTC	2011-04-04	C548723	85063	-1	2011-04-04 09:02:00 UTC	16.95	15874	United Kingdom	CREAM SWEETHEART MAGAZI...
5	2011-12-09 12:50:00 UTC	2011-04-08	549317	23010	1	2011-04-08 09:58:00 UTC	16.95	15109	United Kingdom	CIRCUS PARADE BABY GIFT SET
6	2011-12-09 12:50:00 UTC	2011-11-22	577855	23118	1	2011-11-22 11:18:00 UTC	7.5	15877	United Kingdom	PARISIENNE JEWELLERY DRA...
7	2011-12-09 12:50:00 UTC	2011-04-21	550823	22803	1	2011-04-21 09:36:00 UTC	39.95	16133	United Kingdom	IVORY EMBROIDERED QUILT
8	2011-12-09 12:50:00 UTC	2011-05-19	553742	22448	6	2011-05-19 09:38:00 UTC	3.35	16133	United Kingdom	PIN CUSHION BABUSHKA RED
9	2011-12-09 12:50:00 UTC	2011-08-11	562966	20971	144	2011-08-11 10:53:00 UTC	1.06	16133	United Kingdom	PINK BLUE FELT CRAFT TRINK...
10	2011-12-09 12:50:00 UTC	2011-05-13	553144	23200	100	2011-05-13 13:29:00 UTC	1.79	17669	United Kingdom	JUMBO BAG PEARS
11	2011-12-09 12:50:00 UTC	2011-09-25	568202	21843	1	2011-09-25 15:01:00 UTC	10.95	15366	United Kingdom	RED RETROSPOT CAKE STAND
12	2011-12-09 12:50:00 UTC	2011-06-02	555400	23091	21	2011-06-02 17:50:00 UTC	5.39	14088	United Kingdom	ZINC HERB GARDEN CONTAIN...
13	2011-12-09 12:50:00 UTC	2011-11-23	578305	23539	8	2011-11-23 15:44:00 UTC	5.35	14088	United Kingdom	WALL ART 'LOVES' SECRET
14	2011-12-09 12:50:00 UTC	2011-06-30	558535	84792	1	2011-06-30 12:04:00 UTC	4.65	16904	United Kingdom	ENCHANTED BIRD COATHANG...
15	2011-12-09 12:50:00 UTC	2011-01-19	541525	84946	72	2011-01-19 10:51:00 UTC	1.06	14090	United Kingdom	ANTIQUE SILVER TEA GLASS E...
16	2011-12-09 12:50:00 UTC	2011-11-25	578681	21317	2	2011-11-25 08:41:00 UTC	5.45	13579	United Kingdom	GLASS SPHERE CANDLE STAN...

페이지당 결과 수: 50 1 – 50 (전체 398277행)

- **유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기**

```
select
  customerID,
  max(invoicedate) as InvoiceDay,
from modulabs_project.data
group by customerID;
```

[결과 이미지를 넣어주세요]

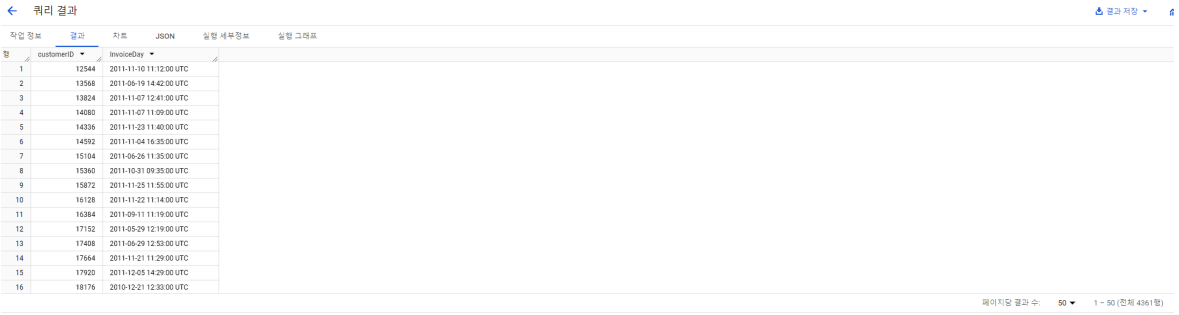

행	customerID	InvoiceDay
1	12544	2011-11-10 11:12:00 UTC
2	13568	2011-06-19 14:42:00 UTC
3	13824	2011-11-07 12:41:00 UTC
4	14080	2011-11-07 11:09:00 UTC
5	14336	2011-11-23 11:40:00 UTC
6	14592	2011-11-04 16:35:00 UTC
7	15104	2011-06-26 11:35:00 UTC
8	15360	2011-10-31 09:35:00 UTC
9	15872	2011-11-25 11:55:00 UTC
10	16128	2011-11-22 11:14:00 UTC
11	16384	2011-09-11 11:19:00 UTC
12	17152	2011-05-29 12:19:00 UTC
13	17408	2011-06-29 12:53:00 UTC
14	17664	2011-11-21 11:29:00 UTC
15	17920	2011-12-05 14:29:00 UTC
16	18176	2010-12-21 12:33:00 UTC

페이지당 결과 수: 50 1 – 50 (전체 4361행)

- **가장 최근 일자(`most_recent_date`)와 유저별 마지막 구매일(`InvoiceDay`)간의 차이를 계산하기**

```
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM modulabs_project.data
  GROUP BY CustomerID
);
```

[결과 이미지를 넣어주세요]

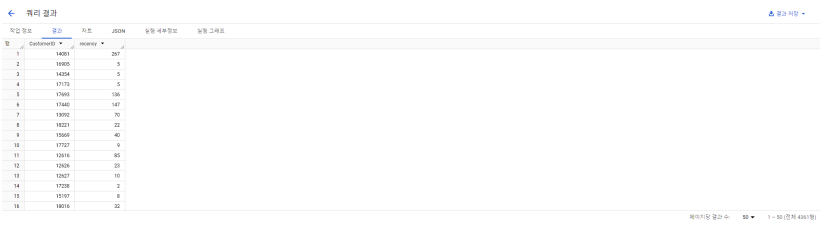

- **최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 `user_r`이라는 이름의 테이블로 저장하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_r AS
# [[YOUR QUERY]]
```

[결과 이미지를 넣어주세요]

Frequency

- **고객마다 고유한 InvoiceNo의 수를 세어보기**

```
SELECT
  CustomerID,
  # [[YOUR QUERY]] AS purchase_cnt
FROM project_name.modulabs_project.data
# [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

- **각 고객 별로 구매한 아이템의 총 수량 더하기**

```
SELECT
  CustomerID,
  # [[YOUR QUERY]] AS item_cnt
FROM project_name.modulabs_project.data
# [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

- **전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_rf AS

-- (1) 전체 거래 건수 계산
WITH purchase_cnt AS (
  # [[YOUR QUERY]]
),

-- (2) 구매한 아이템 총 수량 계산
item_cnt AS (
  # [[YOUR QUERY]]
)

-- 기존의 user_r에 (1)과 (2)를 통합
SELECT
  pc.CustomerID,
  pc.purchase_cnt,
  ic.item_cnt,
  ur.recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
  ON pc.CustomerID = ic.CustomerID
JOIN project_name.modulabs_project.user_r AS ur
  ON pc.CustomerID = ur.CustomerID;
```

[결과 이미지를 넣어주세요]

Monetary

- **고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)**

```
SELECT
  CustomerID,
  # [[YOUR QUERY]] AS user_total
FROM project_name.modulabs_project.data
# [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

- **고객별 평균 거래 금액 계산**
  - **고객별 평균 거래 금액을 구하기 위해 1) `data` 테이블을 `user_rf` 테이블과 조인(LEFT JOIN) 한 후, 2) `purchase_cnt`로 나누어서 3) `user_rfm` 테이블로 저장하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_rfm AS
SELECT
  rf.CustomerID AS CustomerID,
  rf.purchase_cnt,
  rf.item_cnt,
  rf.recency,
  ut.user_total,
  # [[YOUR QUERY]] AS user_average
FROM project_name.modulabs_project.user_rf rf
LEFT JOIN (
  -- 고객 별 총 지출액
  SELECT
    # [[YOUR QUERY]]
) ut
ON rf.CustomerID = ut.CustomerID;
```

[결과 이미지를 넣어주세요]

RFM 통합 테이블 출력하기

- **최종 user_rfm 테이블을 출력하기**

```
# [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

11-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

- **1) 고객 별로 구매한 상품들의 고유한 수를 계산하기**
  2)
  `user_rfm` 테이블과 결과를 합치기
  3)
  `user_data`라는 이름의 테이블에 저장하기

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_data AS
WITH unique_products AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT StockCode) AS unique_products
  FROM project_name.modulabs_project.data
  GROUP BY CustomerID
```

```
)
SELECT ur.*, up.* EXCEPT (CustomerID)
FROM project_name.modulabs_project.user_rfm AS ur
JOIN unique_products AS up
ON ur.CustomerID = up.CustomerID;
```

[결과 이미지를 넣어주세요]

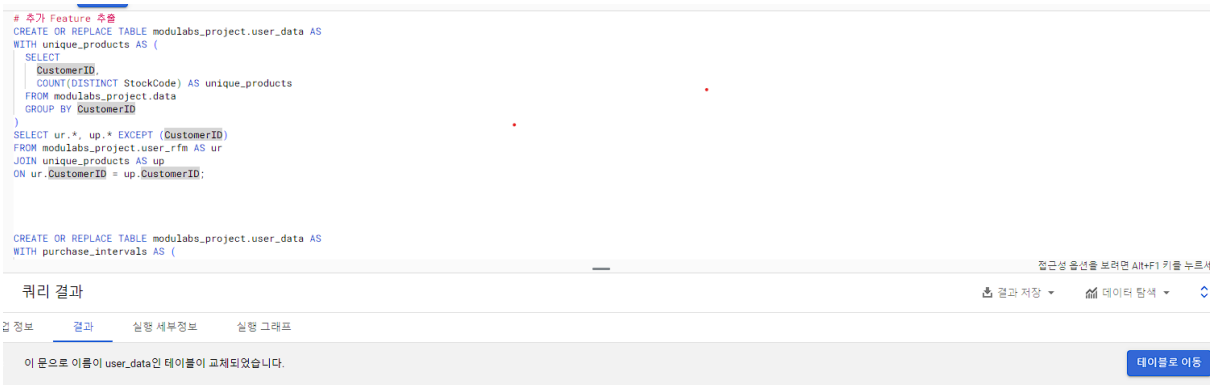

2. 평균 구매 주기

- **고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)**
  - **균 구매 소요 일수를 계산하고, 그 결과를 `user_data` 에 통합**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_data AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
  SELECT
    CustomerID,
    CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_inte
  FROM (
    -- (1) 구매와 구매 사이에 소요된 일수
    SELECT
      CustomerID,
      DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY)
    FROM
      project_name.modulabs_project.data
    WHERE CustomerID IS NOT NULL
  )
  GROUP BY CustomerID
)

SELECT u.*, pi.* EXCEPT (CustomerID)
FROM project_name.modulabs_project.user_data AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

[결과 이미지를 넣어주세요]

3. 구매 취소 경향성

- **고객의 취소 패턴 파악하기**
  1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
  2) 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
  - **취소 빈도와 취소 비율을 계산하고 그 결과를 `user_data` 에 통합하기**
    (취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS

WITH TransactionInfo AS (
  SELECT
    CustomerID,
    count(*) AS total_transactions,
    sum(case when invoiceno like 'C%' then 1 else 0 end) AS cancel_frequency
  FROM modulabs_project.data
  group by CustomerID
)

SELECT u.*, t.* EXCEPT(CustomerID),
round(t.cancel_frequency / t.total_transactions, 2) as cancel_rate
FROM `modulabs_project.user_data` AS u
LEFT JOIN TransactionInfo AS t
ON u.CustomerID = t.CustomerID;

select *
from modulabs_project.user_data;
```

[결과 이미지를 넣어주세요]

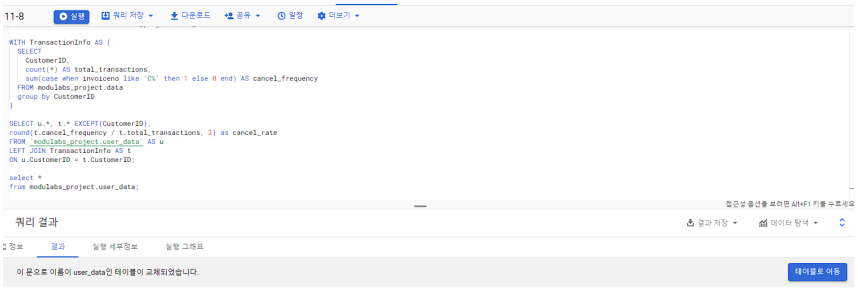

- **다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 `user_data` 를 출력하기**

```
select *
from modulabs_project.user_data;
```

[결과 이미지를 넣어주세요]

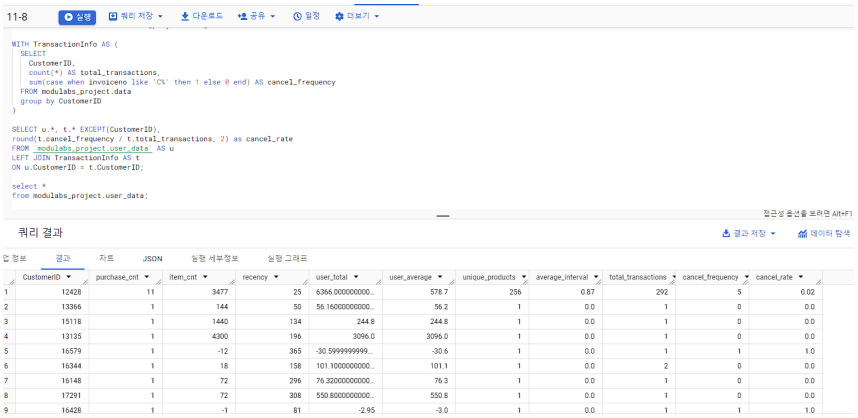

	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_products	average_interval	total_transactions	cancel_frequency	cancel_rate
1	12428	11	3477	25	6366.000000000...	578.7	256	0.87	292	5	0.02
2	13366	1	144	50	56.160000000000...	56.2	1	0.0	1	0	0.0
3	15118	1	1440	134	244.8	244.8	1	0.0	1	0	0.0
4	13135	1	4300	196	3096.0	3096.0	1	0.0	1	0	0.0
5	16579	1	-12	365	-30.599999999...	-30.6	1	0.0	1	1	1.0
6	16344	1	18	158	101.100000000...	101.1	1	0.0	2	0	0.0
7	16148	1	72	296	76.320000000000...	76.3	1	0.0	1	0	0.0
8	17291	1	72	308	550.800000000...	550.8	1	0.0	1	0	0.0
9	16428	1	-1	81	-2.95	-3.0	1	0.0	1	1	1.0